

SK 네트워크 Family AI 32기 : 1팀

학습한 ML / DL 모델

산출물 단계	데이터 전처리
제출 일자	2026. 9. 16.
깃허브 경로	
작성 팀원	이근준

학습한 ML / DL 모델 (Trained ML / DL Model)

1. 모델 개요

- 모델 유형 : ① 입력 문장 분류기 (TF-IDF + 로지스틱 회귀) ② 검색 재정렬 리랭커 (BGE-reranker-v2-m3 + LoRA 파인튜닝)
- 담당 태스크 : ① 공고문 문장이 입력 조건인지 판별 → 자격 판정(gate.py) 근거 확대 ② 검색 후보 30건의 순위 재결정 → 공고 매칭 상위 3건 품질 개선
- 프레임워크 / 버전 : scikit-learn 1.9 · joblib 1.4 · PyTorch 2.11(cu128) · Transformers · PEFT(LoRA) · 학습 환경 RTX 3060 12GB
- 적용 상태 : 두 모델 모두 학습·평가를 마쳤으나 아직 서비스에 연결하지 않았다. 리랭커는 GPU 메모리 8.8GB·질의당 1,079ms 가 필요해 현재 운영 서버(EC2 4GB, CPU)에 그대로 올릴 수 없다.

2. 모델 구조 정의

2.1 구성 요소 (전처리 · 학습 · 후처리)

구성 요소	유형	기능	의존성	비고
전처리 (공통)	normalize.py · doctext.py	HTML 태그 제거 · PDF/HWP 본문 추출	pdfplumber · olefile	두 모델의 입력 원천
특징 (ML)	TfidfVectorizer	글자 2~4개 단위 벡터화 (char_wb)	scikit-learn 1.9	min_df=2 · sublinear_tf
학습기 1 (ML)	LogisticRegression	입력 조건 문장 판별	scikit-learn 1.9	class_weight=balanced
후보 검색 (기존)	BGE-M3 + Chroma	공고 2,153건에서 후보 30건 추출	sentence-transformers · chromadb	사전학습 · 학습 대상 아님
학습기 2 (DL)	BGE-reranker-v2-m3 + LoRA	질의-공고 적합도 예측 후 재정렬	transformers · peft · torch	r=16 · q,k,v · 2 epoch
후처리	확률 구간 3단 매핑	충족 / 미달 / 확인 필요	gate.py 연계	0.35~0.65 는 판단 보류

2.2 입 · 출력 스펙

입·출력 필드	타입	shape / 길이	설명
quote (ML 입력)	str	평균 60자 · 최대 512자	공고문에서 뽑은 입력 근거 문장
age_proba (ML 출력)	float32	[1]	입력 조건일 확률 0.0 ~ 1.0
query / notice (DL 입력)	str 쌍	합쳐서 ≤ 512 토큰	질의문과 공고 문장을 한 쌍으로 입력

relevance (DL 출력)	float32	[후보 수]	질의-광고 적합도 0.0 ~ 1.0 (sigmoid)
ranked (최종 출력)	list	상위 3건	적합도 내림차순 광고 목록

2.3 학습 데이터 · 의존 라이브러리 다이어그램

그림 2-2. 학습 데이터 · 모델 구성 · 의존 라이브러리
두 모델은 서로 독립이다. 입력 분류기는 자격 판정에, 리랭커는 검색 순위에 쓰인다.



3. 모델 저장 및 추론

3.1 저장 · 로딩 파이프라인

- 모델 파일 : ml/models/age_classifier_v2.joblib · ml/models/reranker_lora/(adapter_model.safetensors + adapter_config.json + tokenizer)
- 측정 기준 : 학습·평가는 전부 학습 PC(RTX 3060 12GB)에서 수행했다. 아래 크기·속도·성능은 그 PC 의 실행 산출물(ml/data/reranker_results.json · ml/data/ml_experiments.json)과 실측 로그를 근거로 하며, 2026-09-16 1회 실행 기준이다. 리랭커 어댑터는 용량 때문에 저장소에 포함하지 않으므로 학습 PC 에서 직접 전달한다.

항목	값	단위	측정 조건	서비스 타겟	비고
크기 (입력 분류기)	96	KB	joblib 저장 시	—	TF-IDF 어휘 포함
크기 (리랭커 LoRA)	29.3	MB	safetensors	—	원본 5.7억 파라미터는 별도
학습 시간 (분류기)	1	초 미만	CPU · 249건	—	GPU 불필요
학습 시간 (리랭커)	40	초/epoch	RTX 3060 · 893쌍 · bf16	—	최대 GPU 8.8GB

추론 속도 (리랭커)	1,079	ms	GPU · 질의 1건 · 후보 30건	≤ 200 ms	현 상태로는 미달
----------------	-------	----	-------------------------	---------------	-----------

3.2 성능 · 한계와 후속 연계

구분	항목	값 / 방법	설명 및 관리 방안
성능	업력 분류기	정밀도 0.967 · 재현율 0.879 · F1 0.921	시험 83건 기준. 5-겹 교차검증 F1 0.806 ± 0.023
성능	리랭커	P@3(≥ 1) 0.725 $\rightarrow$ 0.804 · nDCG@3 0.718 $\rightarrow$ 0.862	시험 20질의. 짝지은 95% 구간 $-0.039 \sim +0.196$ 으로 유의성 미확보
저장	포맷 (ML)	joblib (.joblib)	전처리·분류기를 Pipeline 통째로 저장. 선택 설정과 SEED 를 함께 기록
저장	포맷 (DL)	SafeTensors (LoRA 어댑터만)	원본 가중치는 저장하지 않는다. 불러올 때 사전학습 모델에 얹는다
저장	재현	SEED 20260916 · requirements-ml.txt · eval/splits.json	분할·난수·의존성을 고정. 다른 PC 에서 같은 수치를 재현했다
로딩	코드 (ML)	joblib.load('ml/models/age_classifier_v2.joblib')	반환값에 model · uses_hints · abstain 구간이 함께 들어 있다
로딩	코드 (DL)	PeftModel.from_pretrained(base, 'ml/models/reranker_lora')	ml/rerank_common.py 의 Scorer 가 병합(merge_and_unload)까지 처리
추론	입력 일치	ml/rerank_common.notice_text()	학습과 평가가 같은 함수로 문장을 만든다. 한쪽만 바뀌면 점수를 신뢰할 수 없다
한계	서빙 자원	GPU 8.8GB · 1,079 ms/질의	운영 서버(EC2 4GB·CPU)에 미탑재. O NNX 양자화 또는 별도 추론 서버가 필요
한계	평가 규모	시험 질의 20건(정상 17) · 판정 일치율 0.64	차이를 통계적으로 단정할 수 없다. 질의 확대와 사람 판정 확대가 선행되어야 한다
연계	서비스 적용	gate.py 자격 판정 · app.py /api/match	분류기는 「확인 필요」를 줄이는 데, 리랭커는 상위 3건 순위에 연결한다

4. 변경 이력 및 적용 전략

변경일	변경자	변경내용	영향 받는 항목	비고
2026.09.16	이근준	초안 : 업력 분류기·리랭커 2 중 구조 정의 및 학습	전체	v1.0

2026.09.16	이근준	실험 6종 비교 후 최종 모델 확정, 저장·로딩·추론 수치 실측 반영	2.1 · 3.1 · 3.2	v1.1
------------	-----	--	-----------------	------