

SK 네트워크 Family AI 27기 : 1팀

데이터 전처리 결과서

산출물 단계	데이터 전처리
제출 일자	2026. 9. 16.
깃허브 경로	github.com/SKNETWORKS-FAMILY-AICAMP/SKN32-FINAL-1TEAM/tree/main/data-collection
작성 팀원	geunlee00

데이터 전처리 프로세스 (Data Preprocessing)

1. 전처리 개요

- 전처리 목적 : 창업 지원 공고를 공통 스키마로 정규화하고 검색·학습용 데이터셋 생산
- 전처리 범위 : K Startup·기업마당 API → 정규화 → 첨부 추출 → 임베딩·평가 데이터
- 사용 도구 : Python, requests, BeautifulSoup, pdfplumber, hwp5, sentence-transformers, NumPy

2. 원천 데이터 분석

2.1 데이터 출처 및 현황

이슈 유형	대상 필드	판정 기준	처리 방식	처리량 / 비고
수집원	K Startup	API 정상 응답	공통 스키마 변환	239건 (13.5%)
수집원	기업마당	API 정상 응답	공통 스키마 변환	1,533건 (86.5%)
필수값	notice_id·title	NULL / 빈 문자열	거부 큐 기록	거부 0건
중복	source+ source_id	동일 식별자	최종 정상 행 유지	동일 출처 0건
기간	apply_period	5개 유형 분류	미해석은 issues 보존	unknown 54건
첨부	attachment_files	내용 해시	형식별 추출·중복 방지	1,721개 / 650.8 MiB

2.2 품질 이슈 진단

처리 단계	입력	출력	목적
수집 통합	2개 공개 API	raw JSON	원본 보존·재현
스키마 정규화	출처별 필드	normalized JSON	공통 필드 통합
기간 해석	원문 접수기간	5종 period_type	판단 불가 보존
첨부 처리	링크 2,614개	파일 1,721개	해시 중복 방지
임베딩·평가	정제 공고	vector / qrels	검색 학습 자산

2.3 전처리 파이프라인 흐름도

3. 정제·가공·분할 절차 및 후속 활용

3.1 학습 / 검증 / 테스트 분할

- 분할 기준 : qid 또는 scenario_group 단위 그룹 분할, 권장 비율 70:15:15, 고정 seed 사용

필드	타입	결측 처리	중복 처리	이상치 처리	비고
notice_id	STRING	필수	source+ source_id	-	PK
title	TEXT	필수	제목 정제	빈 문자열 거부	검색·표시
body	TEXT	NULL 유지	내용 해시	HTML·길이 정제	임베딩 대상
apply_period	OBJECT	unknown 보존	-	5종 분류	마감 필터
region / subcategory	ARRAY / TEXT	NULL 유지	-	출처별 범위	편향 주의

3.2 후속 단계 활용 적합성 및 재현성 관리

구분	항목	기준 / 결과	설명 및 관리 방안
현황	정규화 공고	1,772건	2026-09-16 최신 스냅샷
현황	기간 유형	fixed 852건	시작일·종료일 구조화
현황	비정형 기간	budget 632 / rolling 143	원문과 유형 동시 보존
현황	기타 기간	until_filled 91 / unknown 54	unknown은 issues 기록
첨부	원본 파일	1,721개 / 650.8 MiB	PDF 936·HWP 527·HWPX 199
벡터	문서 임베딩	$2,153 \times 1,024$	BGE-M3·float32·L2 정규화
학습	평가 질의	60개	정상 52·무관 8
학습	후보 쌍 / qrels	1,657 / 1,317	Dense·BM25 합집합 후 판정
품질	사람 판정	143쌍	최종 성능 검증 우선 집합
품질	LLM 약한 라벨	1,174쌍	운영 채택 전 사람 검수
재현성	단위 테스트	81개 중 68 통과	외부 의존 13개 건너뛸·실패 0

4. 변경 이력 및 적용 전략

변경일	변경자	변경내용	영향 받는 항목	비고
2026.09.16	전체	data-collection 실제 집계값 반영	전체	v2.0
2026.09.16	geunlee00	지정 양식 적용 및 품질 검증 반영	t1 ~ t6	v2.1