

SK 네트워크 Family AI 27기 : _____팀

데이터 전처리 결과서

산출물 단계	데이터 전처리
제출 일자	2026. 4. 18.
깃허브 경로	
작성 팀원	000

데이터 전처리 프로세스 (Data Preprocessing)

1. 전처리 개요

- 전처리 목적 : 멀티 에이전트·RAG 파이프라인에 투입 가능한 학습·검색용 고품질 데이터 생산
- 전처리 범위 : 정형 DB 데이터 및 비정형 문서·로그(원천 → 정제 → 청킹·임베딩)
- 사용 도구 : pandas, numpy, re, kiwipiepy, nltk, scikit-learn, LangChain, sentence-transformers

2. 원천 데이터 분석

2.1 데이터 출처 및 현황

이슈 유형	대상 필드	판정 기준	처리 방식	처리량 / 비교
결측치	content	NULL / 빈 문자열	행 제거	79건
결측치	category	NULL	'기타' 대체	416건
중복치	doc_id	동일 ID	drop_duplicates	124건
중복치	content	SHA1 / MinHash Jaccard ≥ 0.92	대표본 유지	525건
이상치	content_length	< 2자 또는 상위 0.1%	행 제거 또는 분할	60건
형식 불일치	timestamp	ISO-8601 외 포맷	파싱 후 재저장	1,204건

2.2 품질 이슈 진단

처리 단계	입력	출력	목적
형식 정합성	원천 다중 포맷	UTF-8 / ISO-8601	인코딩·스키마 통일
중복 제거	정합 데이터	고유 문서 집합	학습 편향 방지
결측·이상치 처리	고유 문서 집합	정제 코퍼스	품질 확보
정규화 / 마스킹	정제 코퍼스	표준화·마스킹 텍스트	모델 입력 일관·개인정보 보호
분할·청킹	표준화 텍스트	Train/Val/Test + 청크	학습·RAG 동시 구성

2.3 전처리 파이프라인 흐름도

3. 정제·가공·분할 절차 및 후속 활용

3.1 학습 / 검증 / 테스트 분할

● 분할 기준 : 층화 추출 (category 기준, random_state=42)

필드	타입	결측 처리	중복 처리	이상치 처리	비고
doc_id	STRING	필수	drop_duplicates	-	PK
content	TEXT	결측 행 제거	해시 기반	길이 필터	임베딩 대상
category	CATEGORY	'기타' 대체	-	빈도 <5 병합	분류 라벨
intent	CATEGORY	규칙 보강	-	-	의도 분석
timestamp	DATETIME	수집일 대체	-	미래 날짜 제거	ISO-8601

3.2 후속 단계 활용 적합성 및 재현성 관리

구분	항목	기준 / 결과	설명 및 관리 방안
분할	학습	80% (8,000건)	층화 추출 (random_state=42)
분할	검증	10% (1,000건)	조기 종료 판단
분할	테스트	10% (1,000건)	최종 평가용, 학습과 격리
품질	결측 제거	79건	content 기준
품질	중복 제거	649건	해시 + MinHash
품질	이상치 제거	76건	길이·시간 필터
품질	민감정보 마스킹	2,318건 치환	이메일·전화·사번 정규식
후속 활용	ML/DL 학습	CSV · Parquet (label)	XGBoost·BERT 학습 입력
후속 활용	RAG (벡터DB)	JSONL + 청크 메타	512 토큰 · 50 오버랩
후속 활용	GraphDB	트리플 CSV	엔터티 관계 추출
후속 활용 / 재현성	에이전트 호출· 기록	JSON 스키마 + seed/해시 로그	MCP 도구 인자 직렬화, README 명시

4. 변경 이력 및 적용 전략

변경일	변경자	변경내용	영향 받는 항목	비고
2026.04.11	전체	초안 작성 : 전처리 파이프라인 정의	전체	v1.0
2026.04.13	000	품질 이슈 기준 및 RAG 청킹 반영	t3, t4, t6	v1.1